Automatização de códigos em R para cientistas sociais: uma introdução

Natalia Block

4/30/2020

Quando alguém tenta nos convencer de migrar nossas análises estatísticas de softwares como SPSS e Stata para programação em R, geralmente essas são as razões que o sujeito enumera:

1. É totalmente 0800. Você não precisa ficar hackeando número de registro nem usando versão antiga de software.
2. O R tem uma comunidade ativa de pesquisadores e desenvolvedores que aperfeiçoam a linguagem continuamente e geram um extenso material de apoio (gratuito) e documentação. Consequentemente, você tem muito mais recursos e flexibilidade para rodar suas análises em R do que teria em um software engessado com apenas algumas dezenas de funcionalidades.
3. É possível automatizar o tratamento dos dados e análises, o que evita possíveis erros manuais, torna o código mais sucinto e "limpo" e facilita a reprodução das análises por outros pesquisadores.

Se você é de humanas como eu, você provavelmente entendeu e concordou com os itens 1 e 2 mas boiou no 3. A questão é que o item 3 entra em um campo mais complexo para iniciantes e não-técnicos pois pressupõe certo conhecimento da lógica da programação em R. Por mais que os benefícios de se aprender a linguagem sejam muitos, a curva de aprendizagem é longa e exige tempo. O cientista social está preocupado com o seu problema de estudo e a programação é apenas um instrumento, um meio para realizar sua análise. Assim, perdido nos vários trade-offs de como utilizar seu tempo, aprender a automatizar scripts no R acaba não entrando em sua lista de prioridades. Outro obstáculo é que toda a documentação da linguagem, assim como a maior parte do material de apoio, é em inglês e o nível de detalhamento das explicações costuma não ser suficiente para o iniciante.

De forma simples e não-técnica, o que quero dizer com "automatizar códigos" é simplesmente produzir um único bloco de código para realizar uma atividade várias vezes. Ou seja, ao invés de produzir um código para realizar uma alteração em um banco de dados X e copiar e colar esse código para fazer esta mesma alteração em um banco de dados Y, em um código automatizado você define o bloco de código e altera os dois bancos de uma só vez. Nada de Ctrl+C Ctrl+V! Por isso o seu script será mais sucinto e limpo, porque não haverá duplicação de código, ao mesmo tempo que se elimina a possibilidade de erro manual.

O que é este material?

Neste material você encontrará noções básicas para começar a desenvolver códigos automatizados em R. Desenvolvi um tutorial com um cenário mais próximo possível do que um cientista social encontrará no seu dia a dia de trabalho. Iremos coletar, tratar e criar gráficos descritivos para as eleições majoritárias locais no estado do Rio de Janeiro (governador e senador) em quatro eleições. O material não é exaustivo; meu objetivo é apresentar de forma mais detalhada a lógica de programação em R e apenas introduzir os principais elementos, pacotes e funções que lhe permitirão automatizar seus códigos. Porém, você encontrará ao longo da leitura links com material adicional sobre os tópicos e pacotes abordados.

Para quem este material se destina?

Este tutorial se destina a usuários com conhecimento básico a intermediário de R. Estou assumindo que você é capaz de limpar dados com dplyr, plotar gráficos básicos com ggplot e rodar estatísticas descritivas com a base do R. Recomendo que vá lendo e rodando os códigos de forma sequencial para compreender o raciocínio por trás das atividades. Você pode baixar o script aqui "COLOCAR O LINK PARA O GITHUB", mas sugiro ir digitando o código e incluindo comentários no seu script com suas próprias palavras. Por experiência própria, acho que esta é a melhor forma de aprender a programar.

Como o material está estruturado?

O material está dividido em duas seções:

1. Breve revisão de alguns tópicos que serão essenciais para o tutorial:

- vamos tratar rapidamente de algumas estruturas de dados em R: vetores, listas e dataframes;
- vamos falar de funções e como criá-las;
- definiremos o que é iteração. Para isso vamos tratar brevemente de programação imperativa com loop for, e de programação funcional com a família de funções apply (mais particularmente do lapply) e o pacote purrr (especificamente a função map).

2. Aplicação prática desses tópicos no tutorial:

- baixaremos dados eleitorais para o estado do Rio de Janeiro usando o pacote electionsBR;
- faremos a limpeza de quatro bancos de dados simultaneamente, automatizando os códigos com funções criadas por nós e aplicadas aos bancos com a função map do purrr;
- por fim, vamos plotar oito gráficos de uma só vez com ggplot e purrr.

Vamos lá?

Breve revisão de tópicos básicos do R

Resista a tentação de pular esta seção. Você deve estar se perguntando por que precisa ver isso tudo de novo. Já ouvi diversos colegas cientistas sociais que usam R dizerem que não sabem a utilidade de se aprender vetores, listas, etc, se no final das contas praticamente só utilizamos dataframes (no caso de quem trabalha com dados estruturados). É disso que vou tratar aqui.

O R (assim como o Python) é uma linguagem de programação orientada à objetos, ou seja, tudo em R é um objeto. Objetos, por sua vez, são estruturas de dados que podem ser vetores, listas, matrizes, dataframes ou tibbles, funções, só para citar alguns tipos. Quando você abre o console do R ou o RStudio você vê o que chamamos de ambiente (environment) e qualquer objeto criado aí estará alocado no ambiente global (global environment, R_GlobalEnv ou .GlobalEnv) e pode ser acessado ao ser "chamado". Por exemplo, o objeto "nome" a seguir é um vetor da classe characther com meu nome.

```
nome<-c("Natalia", "Maciel", "Block")
```

Para vizualizar esse objeto basta "chamá-lo":

```
nome
```

```
## [1] "Natalia" "Maciel"  "Block"
```

Eu posso saber a classe desse objeto utilizando a função da base R "class" e o seu comprimento utilizando "length".

```
class(nome)
```

```
## [1] "character"
```

```
length(nome)
```

```
## [1] 3
```

Ok, nada de novo até agora. Estou apenas revisitando alguns termos que usaremos mais adiante. O R começa a ter utilidade quando você começa a interagir diferentes tipos de estuturas de objetos. Em grande medida, quando desenvolvemos um código automatizado introduzimos diferentes estuturas de objeto como argumentos de funções criadas por nós. Por sua vez, ao criarmos funções provavelmente teremos que criar objetos temporários, que farão parte da função mas não estarão alocados no ambiente global do R, sendo apenas utilizados quando chamarmos a função criada. Por isso é importante entender esses primeiros conceitos e principalmente as diferenças entre as estruturas de objetos.

Vetores, Listas e Dataframes

Vetores são as estruturas de dado mais básicas do R. Vetores podem ser atômicos ou recursivos (também chamados de listas). Vetores atômicos podem conter apenas elementos do mesmo tipo (logical, interger, double e character), enquanto listas podem conter qualquer tipo de estrutura de dados. Um vetor atômico é criado com c( ), como o objeto "nome" criado anteriormente. Para criar listas, utilizamos a função list( ). Vejamos:

```
#criando um vetor double
meu_vetor<-c(0.14, 0.22, 3, 25)

meu_vetor
```

```
## [1]  0.14  0.22  3.00 25.00
```

```
#criando uma lista
minha_lista<-list(1:10, c(TRUE, FALSE,TRUE), data.frame(v1=(rnorm(20)), v2=rnorm(20)))

str(minha_lista)
```

```
## List of 3
##  $ : int [1:10] 1 2 3 4 5 6 7 8 9 10
##  $ : logi [1:3] TRUE FALSE TRUE
##  $ :'data.frame':    20 obs. of  2 variables:
##   ..$ v1: num [1:20] -0.0677 0.7767 -2.0832 0.9904 1.6917 ...
##   ..$ v2: num [1:20] 0.652 0.235 -0.333 -0.188 1.403 ...
```

A função srt( ) nos mostra a estrutura de um objeto. No objeto "minha_lista" podemos ver que existem 3 elementos, um sequencial inteiro na primeira posição, um vetor logical na segunda e um dataframe na terceira. Assim, vemos que listas comportam diferentes estruturas de dados enquanto vetores podem receber apenas um tipo de dado. Podemos identificar qual é o tipo de vetor utilizando a função typeof( )

```
typeof(meu_vetor)
```

```
## [1] "double"
```

```
typeof(nome)
```

```
## [1] "character"
```

E como acessamos um elemento de uma lista? Digamos que quero ver o vetor logical inserido na lista. Sei que ele está na segunda posição, pois vi quando rodei o str( ). Assim, vamos acessá-lo desta forma:

```
minha_lista[[2]]
```

```
## [1]  TRUE FALSE  TRUE
```

Finalmente o nosso querido dataframe! Dataframes são estruturas bidimensionais constituídas de listas de vetores de igual comprimento. A definição é complicada, mas ela nada mais é do que aquela tão conhecida tabela que você abre no excel ou no SPSS. A informação relevante aqui é que suas dimensões (colunas e linhas) são vetores.

O terceiro elemento da minha_lista é um dataframe. Como podemos fazer uma cópia deste banco em um objeto separado?

```
meu_banco<-minha_lista[[3]]

meu_banco
```

```
##             v1          v2
## 1  -0.06772043  0.65181848
## 2   0.77665246  0.23504536
## 3  -2.08320510 -0.33318645
## 4   0.99044603 -0.18803335
## 5   1.69168817  1.40278160
## 6   0.50612399  0.03419802
## 7   0.38535183  0.46727351
## 8  -1.00819005 -0.98539672
## 9   0.73276466 -0.40835237
## 10 -1.25058631 -1.14144261
## 11 -0.43428276 -0.61999124
## 12 -0.59748406 -0.69038144
## 13 -0.74633047  1.30743758
## 14 -1.10314504  0.09823243
## 15 -0.34607766 -0.47415408
## 16 -0.44873033 -0.77166315
## 17  0.78711906 -0.33033760
## 18  1.17714783 -1.18549468
## 19 -1.43507158  0.69365657
## 20 -0.70343732  1.50229924
```

Material Adicional:

Caso queria se aprofundar nesses elementos básicos do R sugiro o capítulo 20 do já clássico R for Data Science de Wickham e Grolemund. Se você se sente seguro para uma explicação mais avançada leia o capítulo Data Structures do livro Advanced R, também do Hadley Wickham.

Funções

Nas palavras de Hadley Wickham "funções permitem automatizar tarefas comuns de forma mais poderosa e geral do que copiar e colar". Funções reduzem a duplicação, identificando padrões repetidos de código e os extraindo em partes independentes que podem ser atualizadas. Vamos ver isso na prática.

No bloco de código abaixo estou criando um dataframe gerando uma massa de dados aleatórios com uma distribuição normal (função rnorm, que tem como default média= 0 e desvio padrão= 1). Estou arredondando os valores para dois dígitos com a função round. A função set.seed( ) garante que os dados gerados aqui serão os mesmos dados gerados por você na sua máquina. A função head( ) nos dá as primeiras linhas do dataframe criado.

```
set.seed(16)

dados<-data.frame(col1= round(rnorm(100),2),
                  col2= round(rnorm(100),2),
                  col3= round(rnorm(100),2))

head(dados)
```

```
##    col1  col2  col3
## 1  0.48  1.72 -0.36
```

```
## 2 -0.13  0.56  1.17
## 3  1.10  2.63 -0.52
## 4 -1.44  0.50  0.64
## 5  1.15  0.08 -1.53
## 6 -0.47 -0.76  0.23
```

Digamos que eu quisesse calcular a média de cada uma das colunas. A base do R tem a função mean( ) para fazer isso, mas suponhamos que ela não existisse e tivéssemos que elaborar a fórmula. Como seria? No nosso numerador vamos somar os valores de cada elemento (soma das linhas) e o denominador será o número de elementos da distribuição (total de linhas). Assim, para a soma utilizarei a função sum( ) e para contar os elementos utilizarei length( ) que apresentei na seção anterior. Para calcular a média de col1 teríamos:

```
sum(dados$col1)/length(dados$col1)
```

```
## [1] 0.0593
```

Para ver se fizemos certo vamos checar com a função mean( )

```
mean(dados$col1)
```

```
## [1] 0.0593
```

Perfeito! E agora? Como calculamos o resto das médias? Você provavelmente copiaria e colaria a fórmula que criou alterando o nome das colunas, certo? Aqui temos poucas colunas, mas imagine em um banco com 10 variáveis! Isso vai tomar muito do seu tempo e aumentar a possibilidade de erro manual. Além disso, seu código vai ficar gigantesco e horrível de ler. Para evitar essas repetições vamos criar uma função que chamarei de "minha_media".

```
minha_media<-function(coluna){
  sum(coluna)/length(coluna)
}
```

Vamos analisar como essa função foi feita. Antes de tudo estamos atribuindo a função ao objeto minha_media; este será o nome da função. Para criar uma função em R chamamos function( ) e a operação a ser realizada vem logo a seguir dentro dos colchetes. Dentro dos parênteses estamos designando o que chamamos de argumentos da função, que dei o nome de "coluna". Argumentos são geralmente os dados que se quer computar e outros argumentos suplementares que controlam os detalhes do que será computado. Em nossa função minha_media não necessitamos de nenhum argumento suplementar, apenas os dados que estamos computando. Normalmente argumentos suplementares serão detalhes do seu código que se repetem ou outro conjunto de dados. Em minha_media atribuimos o argumento "coluna" porque são os elementos que se repetem na nossa formúla, que serão as colunas do nosso banco de dados. Sei que essa explicação é meio abstrata, mas isso ficará mais claro conforme formos criando mais funções no tutorial.

Vamos ver se a nossa função roda direitinho?

```
minha_media(dados$col1)
```

```
## [1] 0.0593
```

O código está bem mais sucinto e fácil de compreender agora. Porém, ainda temos um problema: para calcular a média das demais colunas teremos que rodar a função minha_media mais duas vezes, ou seja, não eliminamos a repetição. É por isso precisamos entender o que é iteração.

Material Adicional:

Tratei de funções de maneria MUITO superficial, mas esta é uma peça chave para a automatização de códigos. Para aprender mais detalhes você pode fazer o tutorial interativo R Programming: The basics of programming in R do pacote swirl. Foi assim que aprendi a fazer funções. Também recomendo o capítulo 19 do R for Data Science.

Iteração

Iteração é o ato de realizar a mesma operação em múltiplas entradas de dados, ou seja, trata-se de repetir a mesma operação em diferentes colunas ou diferentes bancos de dados, por exemplo. A iteração pode ser realizada por programação imperativa ou funcional.

A programação imperativa faz uso de estruturas de programação como o for loop e o while loop, que torna a iteração bastante explícita no sentido de que é possível literalmente ler como a iteração é feita. No entanto, segundo Wickham, ela é muito verborrágica e acredito que seja por isso que iniciantes são tão resistentes em utilizá-la.

Vamos ver como resolveríamos o nosso problema de calcular todas as médias do nosso banco de dados utilizando o for loop.

```
output<-vector("double", ncol(dados))

for (i in seq_along(dados)){
  output[[i]]<-minha_media(dados[[i]])
}
```

O for loop tem três componentes:

1. **A saída** output<-vector("double", ncol(dados)): antes de rodar o loop é preciso definir o objeto que receberá a saída, ou seja, o resultado do loop. Chamei este objeto de output. É preciso definir que tipo de estrutura de dados será o seu resultado e alocar o espaço que ele tomará. Eu defini que meu resultado será um vetor double com o mesmo número de colunas do dataframe dados.
2. **A sequência** for (i in seq_along (dados)): aqui estou indicando sobre o que estamos iterando. A cada execução do loop for, i recebe um valor diferente da sequência de colunas do dataframe dados. Se fossemos traduzir para bom português o que está escrito nessa linha de código seria: "para cada i ao longo do dataframe dados". Mais precisamente, i são os dados que queremos computar que, no nosso caso, serão as colunas do dataframe "dados".
3. **O corpo** output[[i]]<-minha_media(dados[[i]]): por fim, computamos os dados. Aqui estamos aplicando a função minha_media a cada coluna do dataframe dados - minha_media(dados[[i]]) - e atribuindo cada valor gerado a cada execução do loop ao vetor output que criamos anteriormente - output[[1]].

Vamos ver o resultado?

```
output
```

```
## [1] 0.0593 0.0190 0.0537
```

Em suma, para evitar o CtrC+CtrlV, primeiro definimos a função minha_media e a seguir aplicamos a função a todas as colunas do dataframe de uma só vez utilizando o for loop. Mas o for loop, como mencionei anteriormente, é muito verborrágico e tem uma estrutura muito complexa. Não há nada de errado em utilizar essa estrutura de programação, mas existe uma forma mais fácil e sucinta de fazer a mesma operação. Para isso precisamos entender o que é programação funcional.

Veremos com mais detalhes no tutorial que a linguagem R permite que rodemos funções dentro de funções. Na verdade já fizemos isso anteriormente ao criarmos o nosso dataframe dados. Vamos relembrar esse código?

```
set.seed(16)

dados<-data.frame(col1= round(rnorm(100),2),
                  col2= round(rnorm(100),2),
                  col3= round(rnorm(100),2))
```

Neste bloco de código chamamos a função data.frame( ) para criar a estrutura de dados e dentro dela chamamos a função round( ) para arredondar valores criados pela função rnorm ( ). Chamamos isso de

programação funcional; ao invés de elaborar vários loops ou criar diversas funções para realizar uma operação, inserimos funções dentro de funções, muitas delas já disponíveis em pacotes ou na própria base do R.

Seguindo a lógica da programação funcional, existem dois pacotes desenvolvidos para realizar iterações sem a necessidade de escrever loops: a família de funções apply, da base do R, e as diversas funções map do pacote purrr.

A lógica das funções apply e map são bem parecidas; ao chamá-las você incluirá como argumentos os dados sobre os quais quer iteragir e a função que irá computar estes dados. Para o problema que estamos trabalhando aqui, de calcular as médias das colunas do dataframe dados, faríamos o seguinte:

```
#utilizando lapply

resultado<-lapply(dados, minha_media)

resultado
```

```
## $col1
## [1] 0.0593
##
## $col2
## [1] 0.019
##
## $col3
## [1] 0.0537
```

```
#utilizando a função map do purrr

#caso não tenha o tidyverse ou purrr instalado rode:
#install.packages("tidyverse")

library(tidyverse)
resultado2<-map(dados, minha_media)

resultado2
```

```
## $col1
## [1] 0.0593
##
## $col2
## [1] 0.019
##
## $col3
## [1] 0.0537
```

Como você pode ver as duas funções entregam o mesmo resultado. O que estamos fazendo aqui é rodando funções dentro de funções: minha_media dentro de lapply e de map. Como resultado ambas entregam uma lista em que cada posição estão as as médias de cada coluna. As funções fizeram as mesmas iterações sobre as colunas do dataframe que fizemos com o for loop acima, mas não de maneira explícita. Por isso nosso código fica muito mais sucinto e compreensível.

Como estou utilizando um exemplo muito simples lapply e map acabam parecendo iguais, mas não são. A operacionalização da família de funções apply não é muito sistemática e por isso cada vez mais a comunidade R tem migrado para as funções map do purrr. Além disso, o pacote purrr nos dá maior flexibilidade para trabalhar com dados estruturados de forma automatizada com tibbles, mas isso não será assunto deste tutorial (quem sabe em um próximo?!). Você verá no tutorial que a estrutura de programação do apply e do purrr em contextos mais complexos é um tanto diferente.

Material Adicional:

Quase não tenho utilizado as funções apply pois praticamente só utilizo o purrr para iterações. Mas eu sou da época que o purrr não existia, rsrs. Aprendi a utilizar o apply por tutoriais de internet e pela documentação do R. Esses tutoriais já estão muito ultrapassados e não vale a pena recomendá-los. Caso queira estudar com mais detalhes essas funções recomendo a documentação do R. Digite no console do R: help("lapply"). Para mais detalhes sobre iteração, loops e funções map sugiro o capítulo sobre iteração do R for Data Science.

Tutorial: Eleições para governador e senador no estado do Rio de Janeiro

Hora de aplicar toda essa parafernalha na prática! Vamos baixar dados das eleições de 1998, 2002, 2006 e 2010 do estado do Rio de Janeiro, limparemos os dados, calcularemos a porcentagem de votos recebidas pelos partidos para governador e senador e elaboraremos gráficos de barras comparando os cinco partidos mais bem votados em cada eleição por cargo. Ou seja, ao fim teremos oito gráficos; quatro para a eleição de governador e quatro para senador.

Escolhi essas quatro eleições porque no momento que criei esse tutorial os banco de dados de 2014 e 2018 disponibilizados pelo TSE continham problemas consideráveis como, por exemplo, a incompatibilidade do nome das variáveis com os dados das colunas. Assim, decidi utilizar bancos de dados mais antigos mas que eu sabia que eram consistentes.

Para este exercício vamos utilizar a caixa de ferramentas tidyverse, que contém os pacotes dplyr, ggplot2, purrr, entre outros; o pacote janitor para tabular dados; e o electionsBR para baixar os dados diretamente do site do TSE.

```
#Não esqueça de apontar o seu diretório de trabalho
#setwd(/seu_diretorio_aqui)

#caso não tenha o pacote pacman rode o código comentado abaixo:
#install.packages("pacman")

library(pacman)
p_load(electionsBR, janitor, tidyverse)
```

Como baixamos os dados com o electionsBR? Vamos analisar dados de votação para partido, entõ queremos os dados do banco de votação por partido, município e zona disponibilizado pelo TSE. Assim, vamos utilizar a função party_mun_zone_fed. Os argumentos que esta função recebe são o ano e a uf. A função retornará como resultado um dataframe. Eu sei disso tudo porque li a documentação. Para ver detalhes dos dados que você pode baixar e como utilizar as diversas funções veja a documentação do pacote. Como exemplo vamos baixar os dados das eleições de 1998.

```
el98<-party_mun_zone_fed(1998, uf="RJ")

head(el98)
```

```
## # A tibble: 6 x 21
##   DATA_GERACAO HORA_GERACAO ANO_ELEICAO NUM_TURNO DESCRICAO_ELEIC~ SIGLA_UF
##   <chr>        <time>             <dbl>     <dbl> <chr>            <chr>
## 1 10/03/2016   18:48:28            1998         1 ELEICOES 1998    RJ
## 2 10/03/2016   18:48:28            1998         1 ELEICOES 1998    RJ
## 3 10/03/2016   18:48:28            1998         1 ELEICOES 1998    RJ
## 4 10/03/2016   18:48:28            1998         1 ELEICOES 1998    RJ
## 5 10/03/2016   18:48:28            1998         1 ELEICOES 1998    RJ
## 6 10/03/2016   18:48:28            1998         1 ELEICOES 1998    RJ
## # ... with 15 more variables: SIGLA_UE <dbl>, CODIGO_MUNICIPIO <dbl>,
## #   NOME_MUNICIPIO <chr>, NUMERO_ZONA <dbl>, CODIGO_CARGO <dbl>,
## #   DESCRICAO_CARGO <chr>, TIPO_LEGENDA <chr>, NOME_COLIGACAO <chr>,
```

```
## #   COMPOSICAO_LEGENDA <chr>, SIGLA_PARTIDO <chr>, NUMERO_PARTIDO <dbl>,
## #   NOME_PARTIDO <chr>, QTDE_VOTOS_NOMINAIS <dbl>, QTDE_VOTOS_LEGENDA <dbl>,
## #   SEQUENCIAL_LEGENDA <dbl>
```

Eu sei que ler documentação é muito chato, mas é uma boa prática para que você saiba todas as possibilidades de operacionalização das funções, principalmente quais argumentos ela recebe, que tipo de estruturas de dados ela suporta e que tipo de estrutura de dados ela retorna. O help da função party_mun_zone_fed nos dá a relação de todas as variáveis do banco (digite help("party_mun_zone_fed") no console). Da leitura da documentação sabemos que os bancos apresentam as mesmas variáveis, com exceção de 2018. Desta forma, como os bancos apresentam estruturas similares podemos criar scripts únicos para manipular os quatro bancos de uma só vez.

Utilize o View(el98) para ver o banco por inteiro. Agora que está familiarizado com a "cara" do banco e com a função party_mun_zone_fed lhe pergunto: como baixar os bancos das outras três eleições sem repetir o código?

A documentação não impõem restrição quanto a estrutura de dados que a função recebe como argumento. Desta forma criarei um vetor com os anos eleitorais e o incluirei como argumento da função party_mun_zone_fed que, por sua vez, será chamada dentro da função lapply. Como vimos anteriormente, lapply retorna uma lista. Assim, espero ter como resultado uma lista, que chamarei de rj_list, em que cada posição conterá um banco de dados para cada ano.

Esse bloco de código vai demorar um tempo para rodar porque ele irá lá no site do TSE e vai baixar os dados para os quatro anos. Tenha paciência!

```
#vetor salvando os anos que quero fazer download
anos<-c(1998,2002,2006,2010)

#fazendo download com lapply
rj_list<-lapply(anos, function(anos) party_mun_zone_fed(anos, uf="RJ"))
```

Agora você entende porque é tão importante estudar vetores e listas! Recapitulando: expliquei na revisão que lapply recebe como argumentos os dados a serem computados e a função que irá alterar esses dados, certo? O que fiz acima foi criar um vetor com os dados sobre os quais eu quero que a iteração ocorra, que neste caso são os anos eleitorais. A função é a party_mun_zone_fed, que recebe como argumentos o ano e a uf. Assim, repeti o vetor "anos" também como argumento de party_mun_zone. Tivemos como retorno uma lista com os bancos de dados. Temos aí três elementos apresentados na revisão: o uso de vetores, listas e programação funcional.

Essa operação poderia ter sido realizada com o map do purrr. Farei isso quando baixarmos os dados de comparecimento. Como acessamos os bancos de dados dentro da lista? Eles são salvos dentro da lista pela ordem que foram iterados. Então, na posição 1 está o banco de 1998 e na 4 o de 2010. Vamos verificar?

```
head(rj_list[[1]])
```

```
## # A tibble: 6 x 21
##   DATA_GERACAO HORA_GERACAO ANO_ELEICAO NUM_TURNO DESCRICAO_ELEIC~ SIGLA_UF
##   <chr>        <time>             <dbl>     <dbl> <chr>            <chr>
## 1 10/03/2016   18:48:28            1998         1 ELEICOES 1998    RJ
## 2 10/03/2016   18:48:28            1998         1 ELEICOES 1998    RJ
## 3 10/03/2016   18:48:28            1998         1 ELEICOES 1998    RJ
## 4 10/03/2016   18:48:28            1998         1 ELEICOES 1998    RJ
## 5 10/03/2016   18:48:28            1998         1 ELEICOES 1998    RJ
## 6 10/03/2016   18:48:28            1998         1 ELEICOES 1998    RJ
## # ... with 15 more variables: SIGLA_UE <dbl>, CODIGO_MUNICIPIO <dbl>,
## #   NOME_MUNICIPIO <chr>, NUMERO_ZONA <dbl>, CODIGO_CARGO <dbl>,
## #   DESCRICAO_CARGO <chr>, TIPO_LEGENDA <chr>, NOME_COLIGACAO <chr>,
## #   COMPOSICAO_LEGENDA <chr>, SIGLA_PARTIDO <chr>, NUMERO_PARTIDO <dbl>,
```

```
## #   NOME_PARTIDO <chr>, QTDE_VOTOS_NOMINAIS <dbl>, QTDE_VOTOS_LEGENDA <dbl>,
## #   SEQUENCIAL_LEGENDA <dbl>
```

```
head(rj_list[[4]])
```

```
## # A tibble: 6 x 21
##   DATA_GERACAO HORA_GERACAO ANO_ELEICAO NUM_TURNO DESCRICAO_ELEIC~ SIGLA_UF
##   <chr>        <time>             <dbl>     <dbl> <chr>            <chr>
## 1 27/03/2015   13:22:55            2010         1 ELEIÇÕES 2010    RJ
## 2 27/03/2015   13:22:55            2010         1 ELEIÇÕES 2010    RJ
## 3 27/03/2015   13:22:55            2010         1 ELEIÇÕES 2010    RJ
## 4 27/03/2015   13:22:55            2010         1 ELEIÇÕES 2010    RJ
## 5 27/03/2015   13:22:55            2010         1 ELEIÇÕES 2010    RJ
## 6 27/03/2015   13:22:55            2010         1 ELEIÇÕES 2010    RJ
## # ... with 15 more variables: SIGLA_UE <chr>, CODIGO_MUNICIPIO <dbl>,
## #   NOME_MUNICIPIO <chr>, NUMERO_ZONA <dbl>, CODIGO_CARGO <dbl>,
## #   DESCRICAO_CARGO <chr>, TIPO_LEGENDA <chr>, NOME_COLIGACAO <chr>,
## #   COMPOSICAO_LEGENDA <chr>, SIGLA_PARTIDO <chr>, NUMERO_PARTIDO <dbl>,
## #   NOME_PARTIDO <chr>, QTDE_VOTOS_NOMINAIS <dbl>, QTDE_VOTOS_LEGENDA <dbl>,
## #   SEQUENCIAL_LEGENDA <dbl>
```

Vamos dar nomes aos bancos dentro das listas para ficar mais fácil de se referir a eles. Para isso vou utilizar a função names( ) que recebe um vetor com os nomes que queremos dar para cada um dos bancos.

```
names(rj_list)<-c('el98', 'el02', 'el06', 'el10')

#Vamos dar uma olhada no banco de 2006?
head(rj_list$el06)
```

```
## # A tibble: 6 x 21
##   DATA_GERACAO HORA_GERACAO ANO_ELEICAO NUM_TURNO DESCRICAO_ELEIC~ SIGLA_UF
##   <chr>        <time>             <dbl>     <dbl> <chr>            <chr>
## 1 22/11/2018   19:24:53            2006         1 ELEICOES 2006    RJ
## 2 22/11/2018   19:24:53            2006         2 ELEICOES 2006    RJ
## 3 22/11/2018   19:24:53            2006         1 ELEICOES 2006    RJ
## 4 22/11/2018   19:24:53            2006         2 ELEICOES 2006    RJ
## 5 22/11/2018   19:24:53            2006         1 ELEICOES 2006    RJ
## 6 22/11/2018   19:24:53            2006         1 ELEICOES 2006    RJ
## # ... with 15 more variables: SIGLA_UE <dbl>, CODIGO_MUNICIPIO <dbl>,
## #   NOME_MUNICIPIO <chr>, NUMERO_ZONA <dbl>, CODIGO_CARGO <dbl>,
## #   DESCRICAO_CARGO <chr>, TIPO_LEGENDA <chr>, NOME_COLIGACAO <chr>,
## #   COMPOSICAO_LEGENDA <chr>, SIGLA_PARTIDO <chr>, NUMERO_PARTIDO <dbl>,
## #   NOME_PARTIDO <chr>, QTDE_VOTOS_NOMINAIS <dbl>, QTDE_VOTOS_LEGENDA <dbl>,
## #   SEQUENCIAL_LEGENDA <dbl>
```

Caso prefira ver os dados em formato de tabela use a função View(rj_list$el98). Vá alterando o nome do banco depois do cifrão para visualizar os demais.

Vamos começar a limpar e estruturar nossos bancos. Primeiro quero colocar o nome dos cargos em disputa em letra minúscula pois eles servirão de labels para os nossos gráficos mais adiante. Para isso vamos usar a função tolower( ) para modificar a variável DESCRICAO_CARGO.

Caso ainda tenha dificuldade em pensar em como gerar um código geral para alterar todos os bancos, sugiro que neste início comece criando o bloco para um banco e tente generalizá-lo com base nesse primeiro código. Ao longo do tempo e com a prática você não sentirá mais necessidade de fazer este primeiro passo. Vamos ver como seria.

Primeiro vou desenvolver o código para aquele banco de 1998 que baixamos anteriormente, o el98.

```
el98<-el98%>%
  mutate(DESCRICAO_CARGO=tolower(DESCRICAO_CARGO))

#vamos verificar?
tabyl(el98, DESCRICAO_CARGO)
```

```
##    DESCRICAO_CARGO    n   percent
##  deputado estadual 7559 0.2928143
##   deputado federal 7542 0.2921557
##         governador 3918 0.1517722
##         presidente 3136 0.1214798
##            senador 3660 0.1417780
```

Ok, já sabemos como alterar um banco. Como podemos generalizar esse código para todos os bancos da lista rj_list? Primeiro criarei uma função com base neste código e a seguir irei aplicá-la à lista com a função map. Sei que a variável DESCRICAO_CARGO é a mesma em todos os bancos, desta forma posso usá-la dentro da minha função.

```
minuscula<-function(lista_rj){
   temp<-lista_rj%>%
    mutate(DESCRICAO_CARGO=tolower(DESCRICAO_CARGO))
}
```

Chamei minha função de minuscula. O único argumento que ela receberá é a lista. Veja que o argumento são os dados que quero computar. O objeto temp é um objeto temporário, o que quer dizer que ele não está disponível no ambiente global do R. Ele só é acessado quando utilizamos a função minuscula, essa sim disponível no ambiente global (viu como a revisão era importante?!). Você pode dar qualquer nome a objetos temporários e a argumentos de funções desde que não sejam nomes de funções já existentes na base do R ou de algum outro pacote.

Com a minha função criada, agora posso aplicá-la à lista.

```
rj_list<-map(rj_list, minuscula)
```

Você pode abrir cada banco com o View como fizemos anteriormente. Mas que tal darmos uma olhada em todas as alterações de uma só vez? Vou usar o tabyl do janitor dentro da função map para tabularmos a variável DESCRICAO_CARGO de todos os bancos.

```
map(rj_list, ~tabyl(.x, DESCRICAO_CARGO))
```

```
## $el98
##    DESCRICAO_CARGO    n   percent
##  deputado estadual 7559 0.2928143
##   deputado federal 7542 0.2921557
##         governador 3918 0.1517722
##         presidente 3136 0.1214798
##            senador 3660 0.1417780
##
## $el02
##    DESCRICAO_CARGO    n      percent valid_percent
##  deputado estadual 7582 3.454057e-01     0.3454214
##   deputado federal 7843 3.572958e-01     0.3573121
##         governador 2343 1.067377e-01     0.1067426
##            senador 4182 1.905152e-01     0.1905239
##               <NA>    1 4.555601e-05            NA
##
## $el06
```

```
##    DESCRICAO_CARGO    n   percent
##  deputado estadual 7242 0.3140367
##   deputado federal 7281 0.3157279
##         governador 3398 0.1473483
##         presidente 2365 0.1025541
##            senador 2775 0.1203330
##
## $el10
##    DESCRICAO_CARGO    n    percent
##  deputado estadual 6835 0.38819788
##   deputado federal 6828 0.38780031
##         governador 1578 0.08962345
##            senador 2366 0.13437837
```

Veja aqui que, como alertei anteriormente, map e lapply começam a apresentar diferenças conforme a complexidade do contexto. Neste caso, tabyl é uma função que recebe dois argumentos, o conjunto de dados e o nome da variável que se quer alterar. O conjunto de dados será o mesmo do argumento de map, que é a lista rj_list. Assim, na estrutura do map, tabyl deve ser incluído seguido de um til de forma que o map interpretará .x como o mesmo conjunto de dados inserido como argumento do map. E como eu sei disso? Porque li a documentação. Vamos fazer isso juntos. Vamos começar interpretando a documentação do map:

```
??map
```

Leia a descrição, as formas de uso e os tipos de estrutura de dados que os argumentos que a função recebem. O que a descrição da função nos diz é que map recebe como argumentos .x, que deve ser uma lista ou um vetor, e .f que é uma função, formula ou vetor (no nosso caso é uma função) e dá como retorno uma lista. Neste sentido o .x é a nossa lista rj_list e .f é a função tabyl.

Agora vamos ler a documentação de tabyl:

```
??tabyl
```

Da leitura da documentação sabemos que tabyl recebe como argumentos dat que será um dataframe e ... que são os vetores, ou colunas do banco que queremos sumarizar, e o retorno será um dataframe com a sumarização dos dados. No entanto, estamos usando a função tabyl como um argumento de map então os dataframes gerados por tabyl estão dentro de uma lista gerada por map. Por isso, como você vê, temos no resultado o nome do banco dentro da lista ($el98, $el02, etc) com os respectivos resultados do tabyl.

Novamente, sei que é um saco ler documentação, mas é assim que você aprenderá a programar com mais eficiência.

Antes de começarmos a tratar os bancos vamos verificar se eles são realmente iguais. Podemos começar verificando se eles tem a mesma quantidade de colunas. Para isso vou usar a função dim e aplicá-la a todos os bancos com map.

```
map(rj_list, dim)
```

```
## $el98
## [1] 25815    21
##
## $el02
## [1] 21951    21
##
## $el06
## [1] 23061    21
##
## $el10
## [1] 17607    21
```

Sim, elas têm a mesma quantidade de colunas. Mas será que as colunas são iguais? Como podemos verificar se o nome das colunas são iguais sem ter que abrir e vasculhar todos os bancos? Uma opção seria salvar o nome das colunas de cada banco e depois compará-los. Faço isso a seguir:

```
#guardando o nome de todas as colunas
nome_col<-map(rj_list, colnames)

#verificando as colunas são iguais em todos os bancos
nome_col$el98==nome_col$el02
```

```
##  [1] TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE
## [16] TRUE TRUE TRUE TRUE TRUE TRUE
```

```
nome_col$el02==nome_col$el06
```

```
##  [1] TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE
## [16] TRUE TRUE TRUE TRUE TRUE TRUE
```

```
nome_col$el06==nome_col$el10
```

```
##  [1] TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE
## [16] TRUE TRUE TRUE TRUE TRUE TRUE
```

O que fiz foi salvar todos os nomes das colunas com a função colnames, aplicando-o à lista com map. O colnames salva um vetor com os nomes; os vetores foram salvos na lista nome_col com o map. A seguir comparei os vetores. A comparação retorna um vetor boleano. Caso houvesse alguma coluna diferente teríamos FALSE como retorno na posição em que o R encontrasse a discrepância. Como tivemos apenas TRUE como retorno estamos seguros de que todas as colunas apresentam os mesmos nomes nos quatro bancos.

Enfim podemos começar a estruturar o banco. Queremos trabalhar apenas com eleições majoritárias (governador e senador), no primeiro turno (no caso de governador).

O que precisaremos fazer? 1) Selecionar as variáveis de interesse que serão NUM_TURNO, DESCRICAO_CARGO, SIGLA_PARTIDO, QTDE_VOTOS_NOMINAIS; 2) Filtrar apenas primeiro turno e os cargos de interesse (governador, senador); 3) Agrupar as linhas e somar o total de votos por partido

Como seria se eu fizesse isso tudo para apenas um banco? Vamos continuar testando no banco el98.

```
maj98<-el98%>%
  select(NUM_TURNO, DESCRICAO_CARGO, SIGLA_PARTIDO, QTDE_VOTOS_NOMINAIS)%>%
  filter(NUM_TURNO==1 & DESCRICAO_CARGO %in% c("governador", "senador"))%>%
  group_by(DESCRICAO_CARGO, SIGLA_PARTIDO)%>%
  summarise(votos=sum(QTDE_VOTOS_NOMINAIS))

glimpse(maj98)
```

```
## Rows: 27
## Columns: 3
## Groups: DESCRICAO_CARGO [2]
## $ DESCRICAO_CARGO <chr> "governador", "governador", "governador", "governad...
## $ SIGLA_PARTIDO   <chr> "PDT", "PFL", "PPS", "PRONA", "PRTB", "PSDB", "PSDC...
## $ votos           <dbl> 3083441, 2256815, 74154, 63154, 7684, 1020765, 4515...
```

Beleza! A seguir, farei uma função, a limpa_votos, com base nesta e a aplicarei à lista rj_list com map. Vou salvar o resultado em uma lista separada, que chamarei de maj_rj, para termos os dados brutos salvos caso sejam necessários futuramente.

```
#Criando a função:
```

```
limpa_voto<-function(lista_votos){
  obj_temp<-lista_votos%>%
    select(NUM_TURNO, DESCRICAO_CARGO, SIGLA_PARTIDO, QTDE_VOTOS_NOMINAIS)%>%
    filter(NUM_TURNO==1 & DESCRICAO_CARGO %in% c("governador", "senador"))%>%
    group_by(DESCRICAO_CARGO, SIGLA_PARTIDO)%>%
    summarise(votos=sum(QTDE_VOTOS_NOMINAIS))
}

#aplicando à lista com map
maj_rj<-map(rj_list, limpa_voto)
```

Temos o nosso banco de votação pronto. Para calcularmos a porcentagem de votos recebidos precisamos dos dados de comparecimento por ano. Eles estão no banco detalhes de votação do TSE e podem ser baixados pelo pacote electionsBR com a função details_mun_zone_fed. Vou utilizar a função map para isso. Repare que vou utilizar o mesmo vetor anos que utilizei para baixar os dados de votação anteriormente.

```
comp_list<-map(anos, ~details_mun_zone_fed(.x,"RJ"))
```

A seguir irei nomear os bancos dentro da lista comp_list, verificar se os bancos são iguais e colocar os cargos da variável DESCRICAO_CARGO em letra minúscula, como fiz no banco anterior.

```
#Nomeando os bancos dentro da lista. Vou dar o mesmo nome que dei aos bancos na lista rj_list
names(comp_list)<-c('el98', 'el02', 'el06', 'el10')
names(comp_list)
```

```
## [1] "el98" "el02" "el06" "el10"
```

```
#Verificando se as dimensões dos bancos são iguais
map(comp_list, dim)
```

```
## $el98
## [1] 1310   26
##
## $el02
## [1] 1052   26
##
## $el06
## [1] 1315   26
##
## $el10
## [1] 1052   26
```

```
#Agora vou verificar se as colunas são iguais:

#Salvando o nome de todas as colunas em uma lista com a função map
nome_col_comp<-map(comp_list, colnames)

#Verificando se os nomes das colunas são iguais em todos os bancos
nome_col_comp$el98==nome_col_comp$el02
```

```
##  [1] TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE
## [16] TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE
```

```
nome_col_comp$el02==nome_col_comp$el06
```

```
##  [1] TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE
## [16] TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE
```

```
nome_col_comp$el06==nome_col_comp$el10
```

```
##  [1] TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE
## [16] TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE TRUE
```

```
#Agora preciso colocar os cargos em letra minúscula.
#Não tem segredo; vamos utilizar a mesma função "minuscula" já criada e aplicá-la a lista
#comp_list com map.

comp_list<-map(comp_list, minuscula)

#por fim, vamos confirmar se a alteração foi feita

map(comp_list,~tabyl(.x, DESCRICAO_CARGO))
```

```
## $el98
##    DESCRICAO_CARGO   n percent
##  deputado estadual 262     0.2
##   deputado federal 262     0.2
##         governador 524     0.4
##            senador 262     0.2
##
## $el02
##    DESCRICAO_CARGO   n percent
##  deputado estadual 263    0.25
##   deputado federal 263    0.25
##         governador 263    0.25
##            senador 263    0.25
##
## $el06
##    DESCRICAO_CARGO   n percent
##  deputado estadual 263     0.2
##   deputado federal 263     0.2
##         governador 526     0.4
##            senador 263     0.2
##
## $el10
##    DESCRICAO_CARGO   n percent
##  deputado estadual 263    0.25
##   deputado federal 263    0.25
##         governador 263    0.25
##            senador 263    0.25
```

Tudo está ok com os bancos. Hora de limpá-lo. O que precisamos fazer? 1) Selecionar as variáveis que precisamos: NUM_TURNO, DESCRICAO_CARGO, QTD_COMPARECIMENTO; 2) Filtrar apenas primeiro turno e os cargos de interesse (governador, senador); 3) Agrupar as linhas e somar o total de votos por cargo. Como estamos trabalhando com primeiro turno os valores serão iguais para os dois cargos.

Como já fizemos várias vezes anteriormente, farei uma função para limpar o banco e a aplicarei à lista com map. Salvarei o resultado no objeto comp_rj para não alterar os dados brutos.

```
#criando a função
limpa_comp<-function(lista_comp){
  temp<-lista_comp %>%
  select(NUM_TURNO, DESCRICAO_CARGO, QTD_COMPARECIMENTO)%>%
  filter(NUM_TURNO==1 & DESCRICAO_CARGO %in% c("governador", "senador"))%>%
```

```
  group_by(DESCRICAO_CARGO)%>%
  summarise(comparecimento=sum(QTD_COMPARECIMENTO))
}

#aplicando à lista
comp_rj<-map(comp_list, limpa_comp)
```

Finalmente temos nossos dois bancos. Agora precisamos trazer o total de comparecimento para os bancos de votação e fazer o cálculo da votação. No bloco a seguir crio a função para isso.

```
calcula_comp<-function(lista_maj, lista_comp){
  lista_maj%>%
  left_join(lista_comp)%>%
    mutate(porc_voto=(round(votos*100/comparecimento, 2)))
}
```

Repare que na função que criei receberá como argumentos dois conjuntos de dados distintos: a lista com os bancos de votação e a lista com os bancos de dados de comparecimento. Desta forma, teremos dois conjuntos de dados iterando com a função calcula_comp. No caso de termos mais de uma entrada de dados utilizamos outra função do purrr, a map2. Vejamos na documentação como ela funciona:

```
??map2
```

A lógica é basicamente a mesma do map, mas como a função que criamos recebe dois argumentos precisamos identificar na função map 2 quem o que será cada argumento (.x e .y).

```
maj_rj<-map2(.x = maj_rj, .y = comp_rj, ~ calcula_comp(.x,.y))
```

```
## Joining, by = "DESCRICAO_CARGO"
## Joining, by = "DESCRICAO_CARGO"
## Joining, by = "DESCRICAO_CARGO"
## Joining, by = "DESCRICAO_CARGO"
```

Perfeito! Estamos prontos para elaborar nossos gráficos. Queremos fazer gráficos de barras comparando a votação dos cinco partidos mais bem votados em cada eleição para cada cargo. Iremos, então, plotar ao total oito gráficos: quatro para senador (1998, 2002, 2006, 2010) e quatro para governador (idem). Desse modo, a nossa função terá que: 1) filtrar o cargo; 2) elencar as cinco maiores votações; 3) transformar as siglas dos partidos em fatores; 4) criar o gráfico de barras com ggplot2.

```
gf_barras<-function(banco, ano, cargo){
  temp<-banco%>%
    filter(DESCRICAO_CARGO== cargo)%>%
    top_n(5)%>%
    arrange(desc(porc_voto))%>%
    mutate(SIGLA_PARTIDO=factor(SIGLA_PARTIDO, levels = unique(SIGLA_PARTIDO)))%>%
    ggplot()+
    geom_bar(aes(x=SIGLA_PARTIDO, y=porc_voto), stat = "identity", width = 0.7, fill="turquoise4")+
    labs(title=glue::glue("Votação para ", cargo," no estado do Rio de Janeiro em ", ano),
         x= " ",
         y= "(%)",
         caption = "Fonte: TSE") +
    theme(plot.title = element_text(size=12))+
    theme_bw()
}
```

Veja que a função que criei recebe três argumentos: os bancos de dados da lista, o ano da eleição e o cargo. Estes são os elementos que serão alterados a cada vez que utilizarmos a função. O banco será a nossa lista.

Como iremos aplicar a função a todos os bancos de uma vez com o map2, utilizaremos o vetor anos no argumento ano e o argumento cargo receberá uma string com o nome do cargo que queremos, que deve ser governador ou senador. Não vou explicar com detalhes os códigos do dplyr e do ggplot utilizados aqui, mas quero ressaltar uma linha que é bastante interessante. Veja que para adicionar o título estou usando a função glue, que irá colar no texto que escrevi o nome do cargo e o ano em cada iteração.

Vamos ver como ficou?

```
#plotando gráficos para eleição de governador
map2(.x= maj_rj,
     .y= anos,
     .f= ~gf_barras(.x, .y, "governador"))
```

```
## Selecting by porc_voto
## Selecting by porc_voto
## Selecting by porc_voto
## Selecting by porc_voto
```

```
## $el98
```

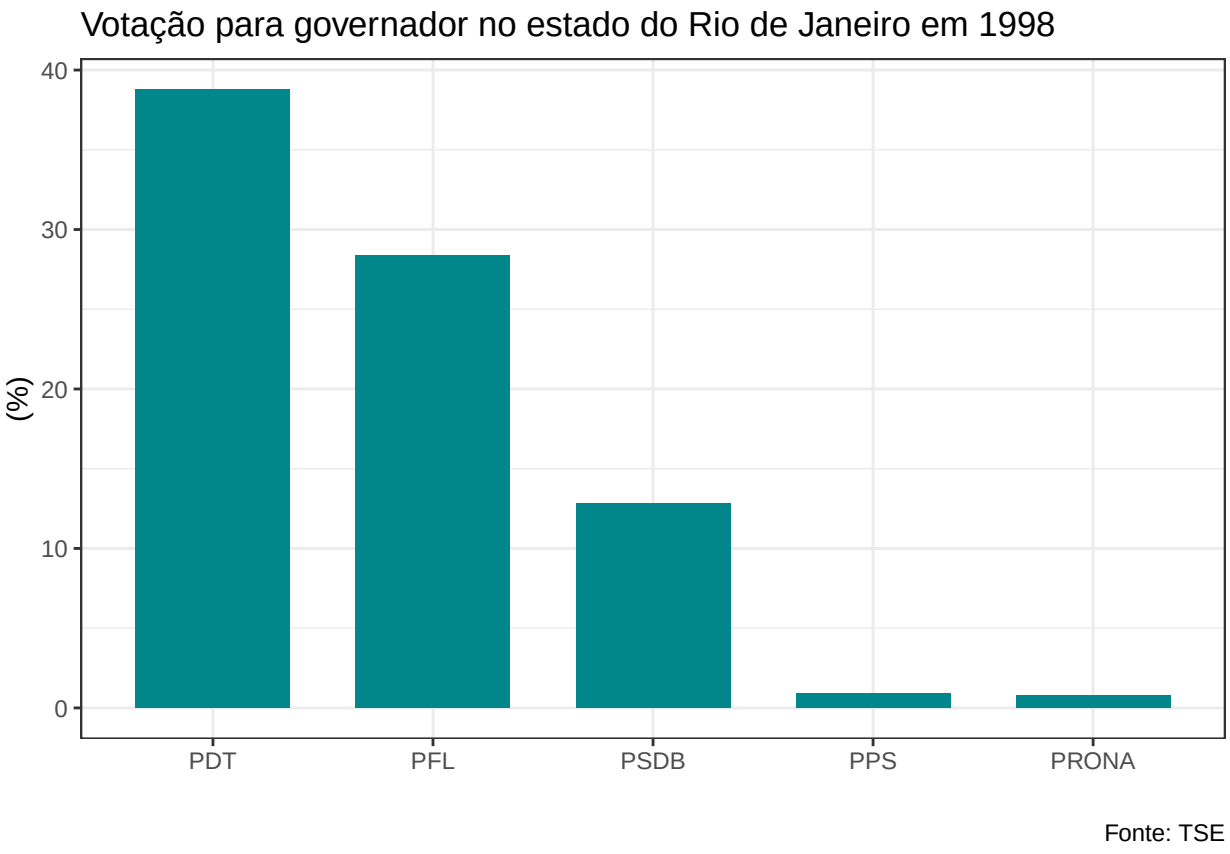


```
##
## $el02
```

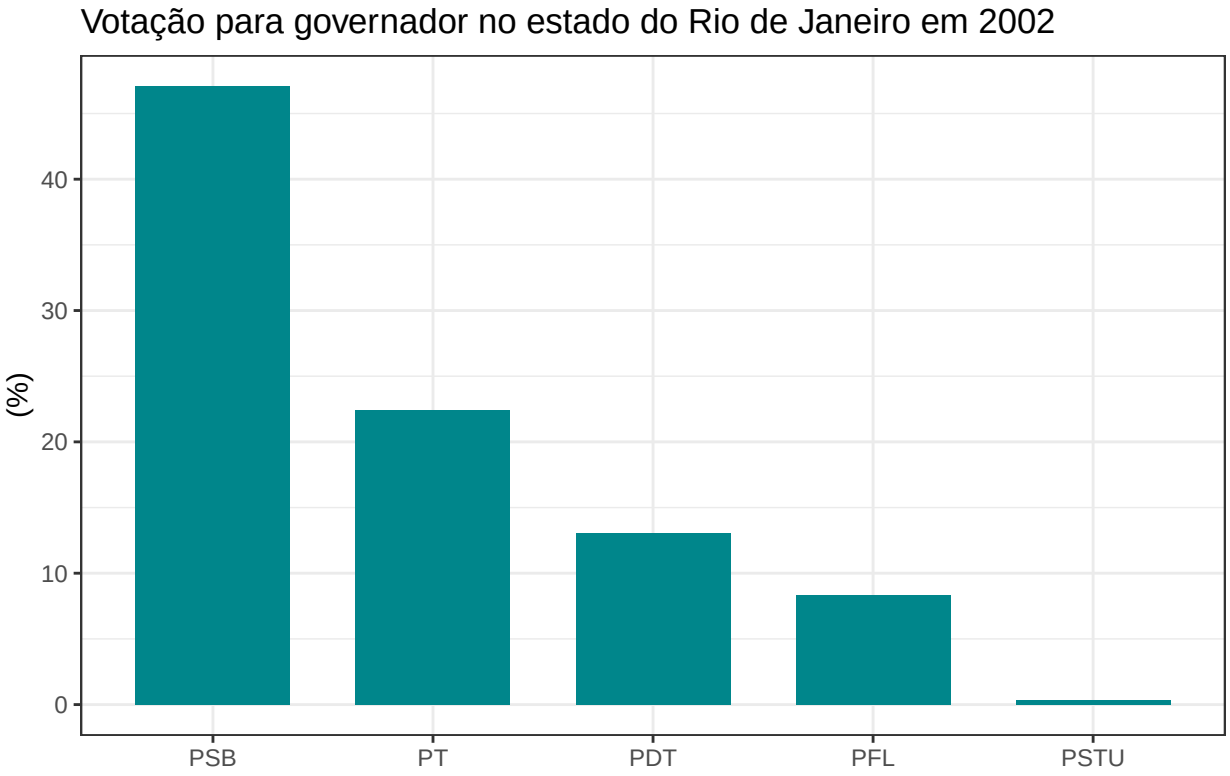

Fonte: TSE

```
##
## $el06
```

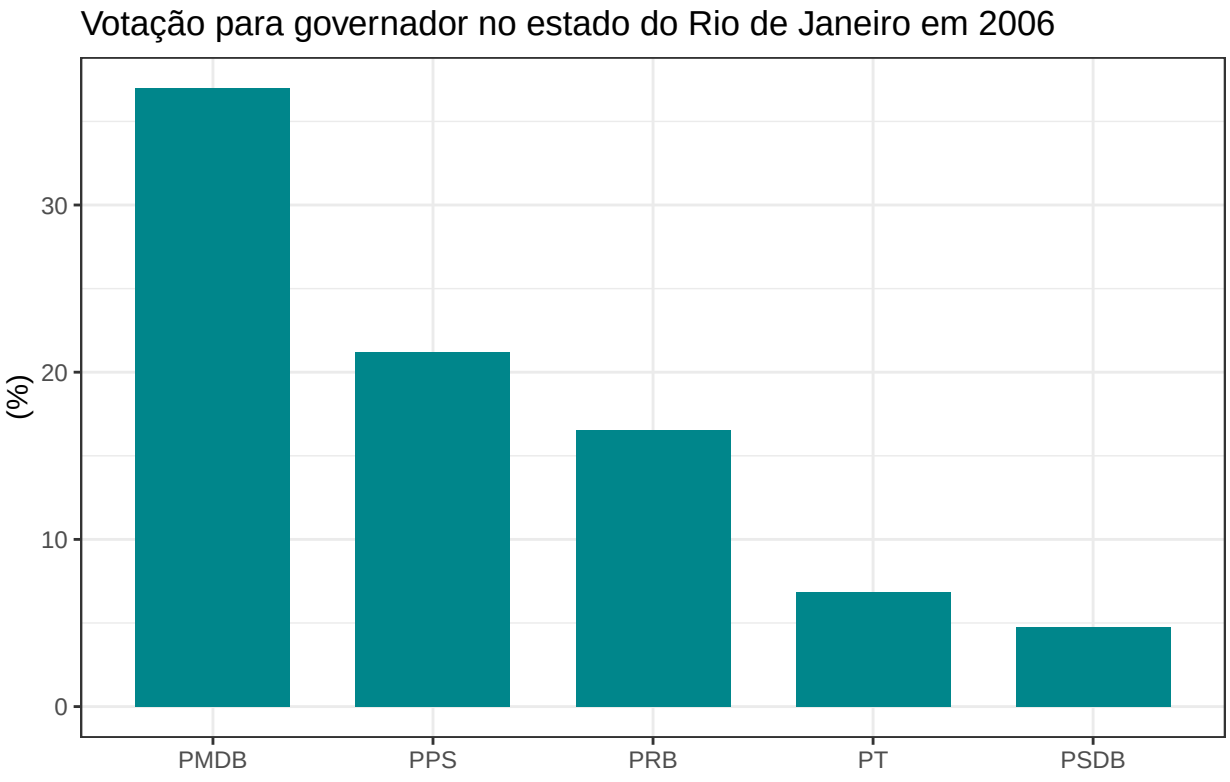

Fonte: TSE

```
##
## $el10
```

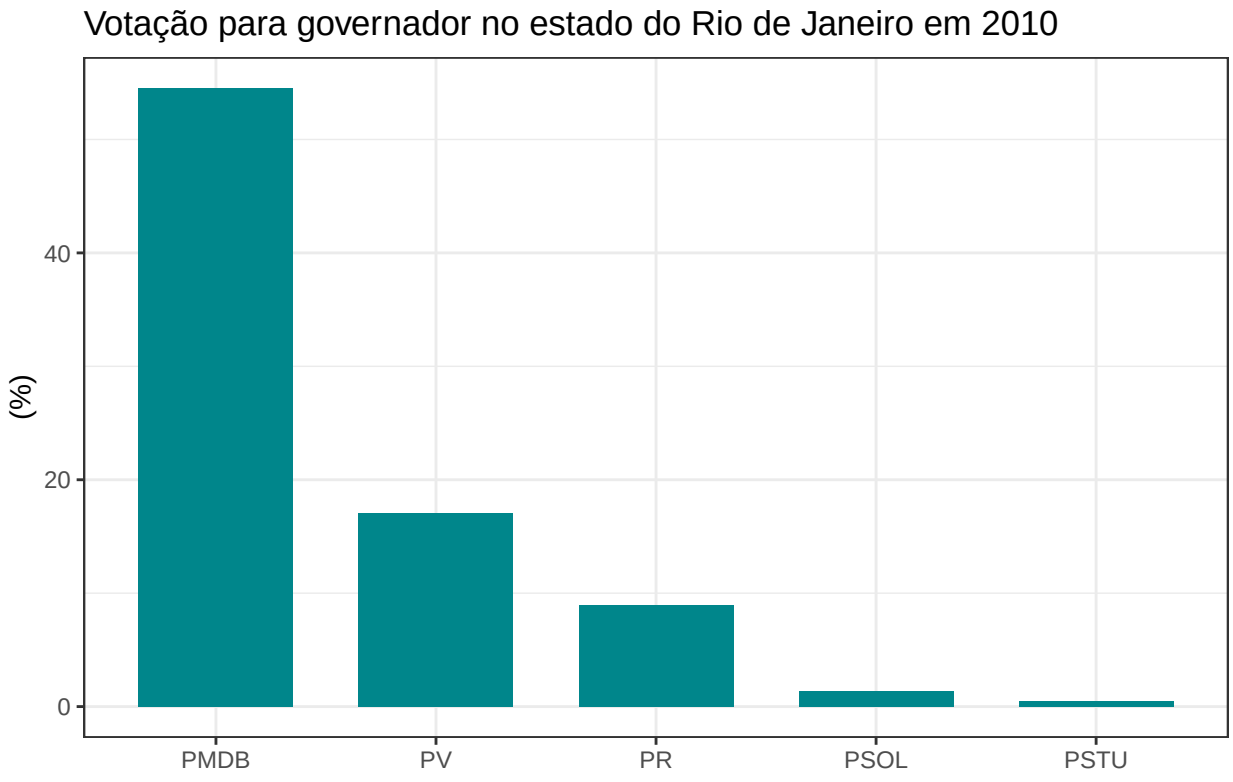

Fonte: TSE

```
#agora para eleições de senador
map2(.x= maj_rj,
     .y= anos,
     .f= ~gf_barras(.x, .y, "senador"))
```

```
## Selecting by porc_voto
## Selecting by porc_voto
## Selecting by porc_voto
## Selecting by porc_voto
```

```
## $el98
```

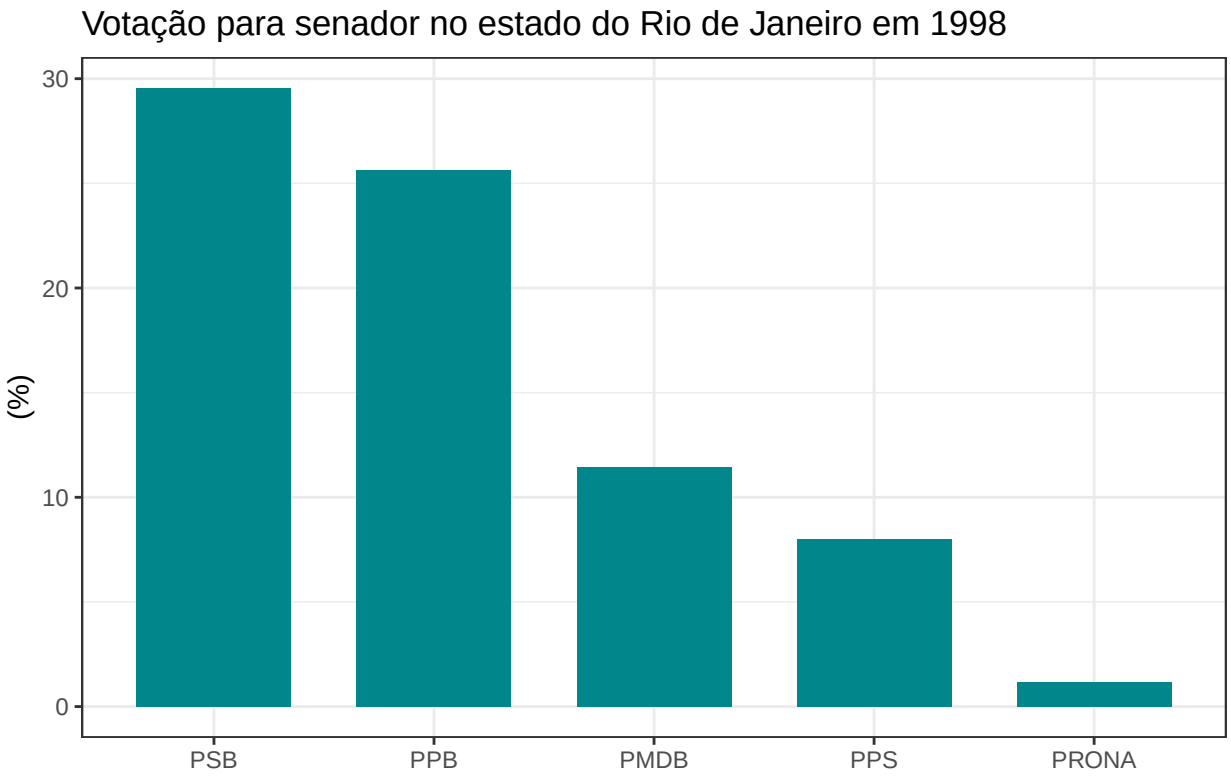

Fonte: TSE

```
##
## $el02
```

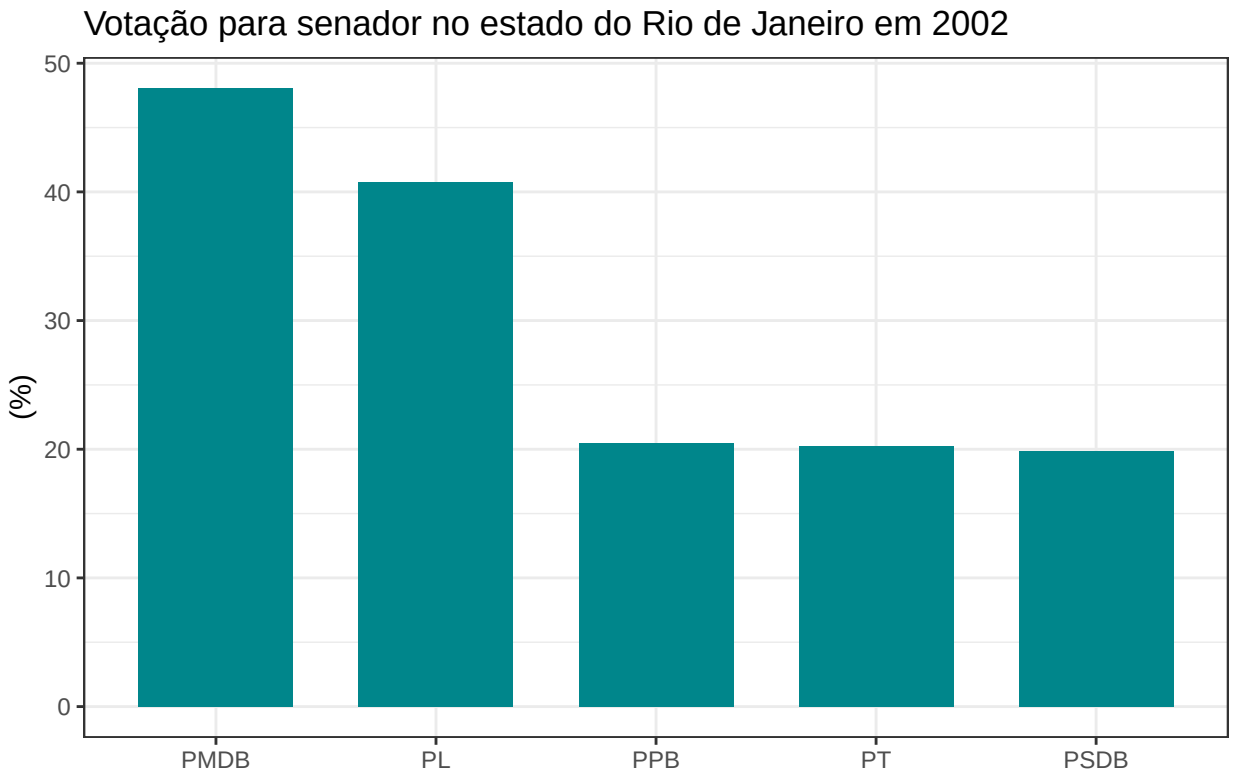

Fonte: TSE

```
##
## $el06
```

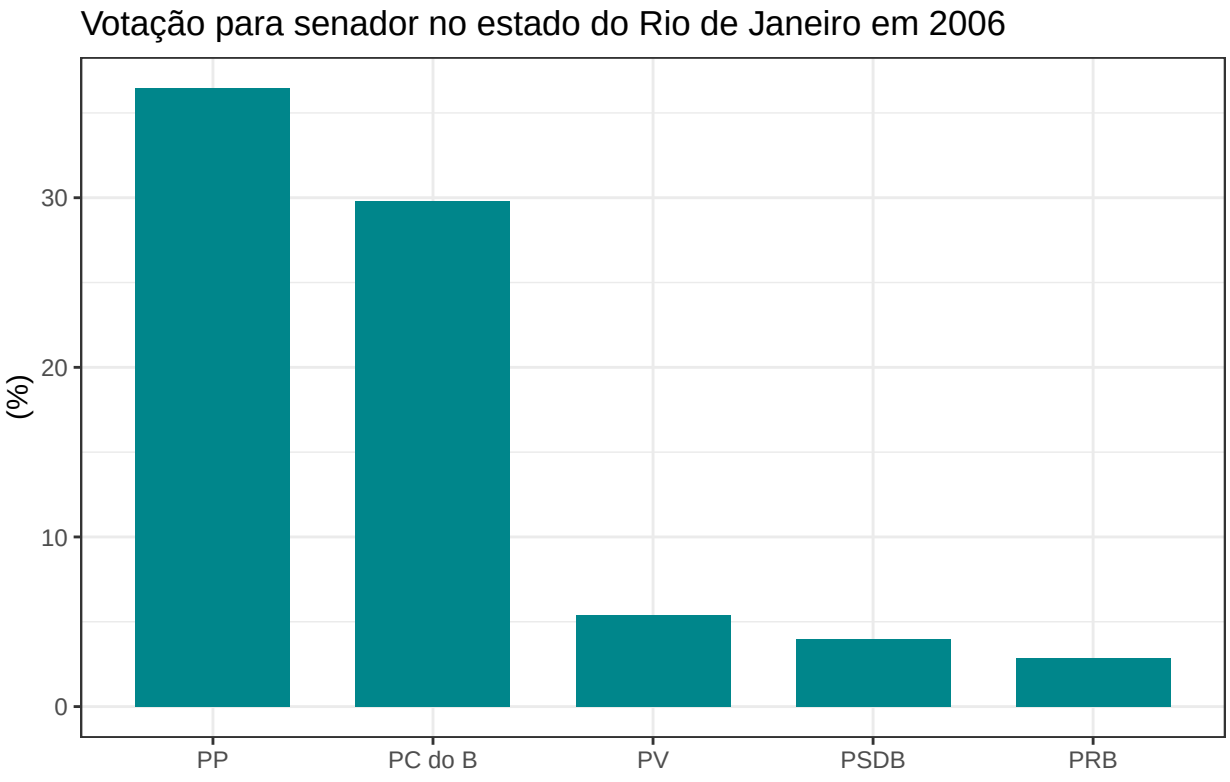

Fonte: TSE

```
##
## $el10
```

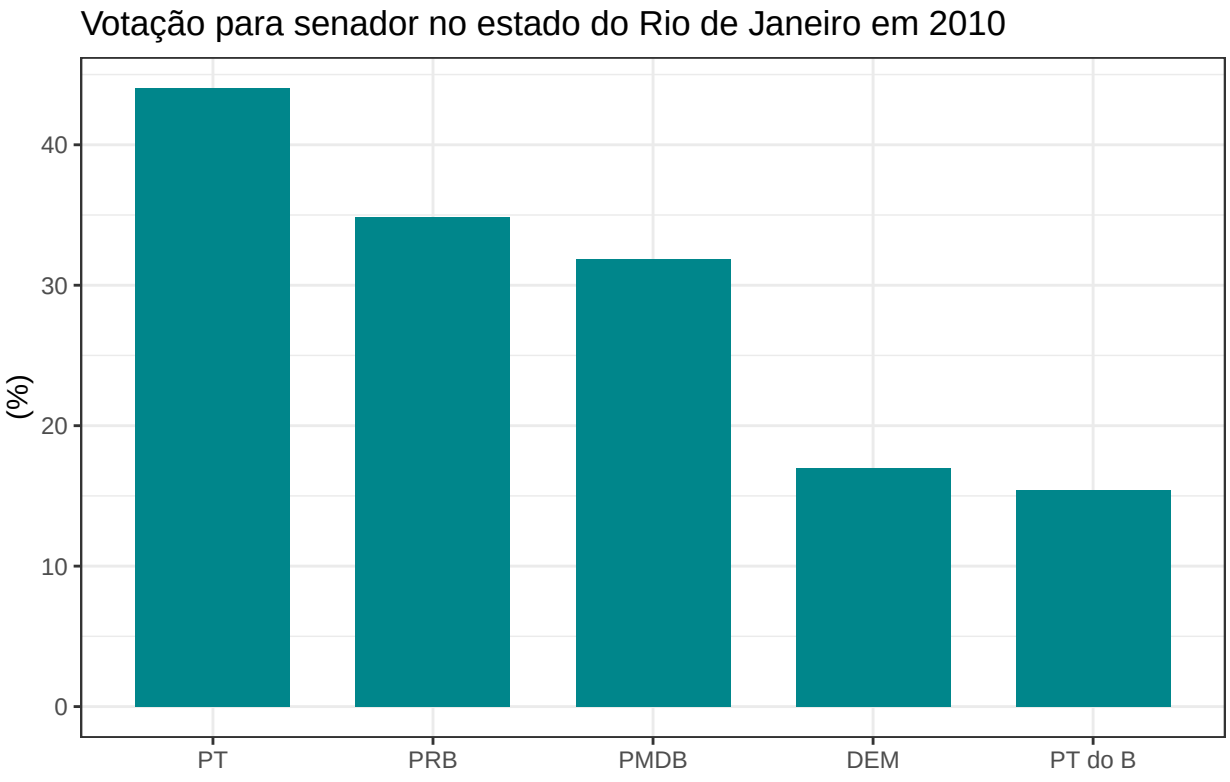

Ficou é ótimo, mas uma coisa ainda me incomoda. Tenho todos os gráficos com a mesma cor, acho que ficaria melhor se pudesse escolher cores diferentes para cada cargo. Vou alterar a função que criei anteriormente para receber um quarto argumento que será a cor que o ggplot irá receber no aestetics fill para colorir as barras. Estou dando um outro nome a esta função.

```
gf_barras_cor<-function(banco, ano, cargo, cores){
  temp<-banco%>%
    filter(DESCRICAO_CARGO== cargo)%>%
    top_n(5)%>%
    arrange(desc(porc_voto))%>%
    mutate(SIGLA_PARTIDO=factor(SIGLA_PARTIDO, levels = unique(SIGLA_PARTIDO)))%>%
    ggplot()+
    geom_bar(aes(x=SIGLA_PARTIDO, y=porc_voto), stat = "identity", width = 0.7, fill=cores)+
    labs(title=glue::glue("Votação para ", cargo," no estado do Rio de Janeiro em ", ano),
         x= " ",
         y= "(%)",
         caption = "Fonte: TSE") +
    theme(plot.title = element_text(size=12))+
    theme_bw()
}
```

Perceba que o argumento cores só irá receber nome de cores que são suportadas pelo ggplot2. Aqui você encontra a lista de cores que pode utilizar.

Eu vou manter essa cor verde nos gráficos de governador, mas quero uma cor vermelha para os de senador.

```
map2(.x=maj_rj,
     .y=anos,
     .f= ~gf_barras_cor(.x, .y, "governador", "turquoise4"))
```

```
## Selecting by porc_voto
## Selecting by porc_voto
## Selecting by porc_voto
## Selecting by porc_voto
```

```
## $el98
```

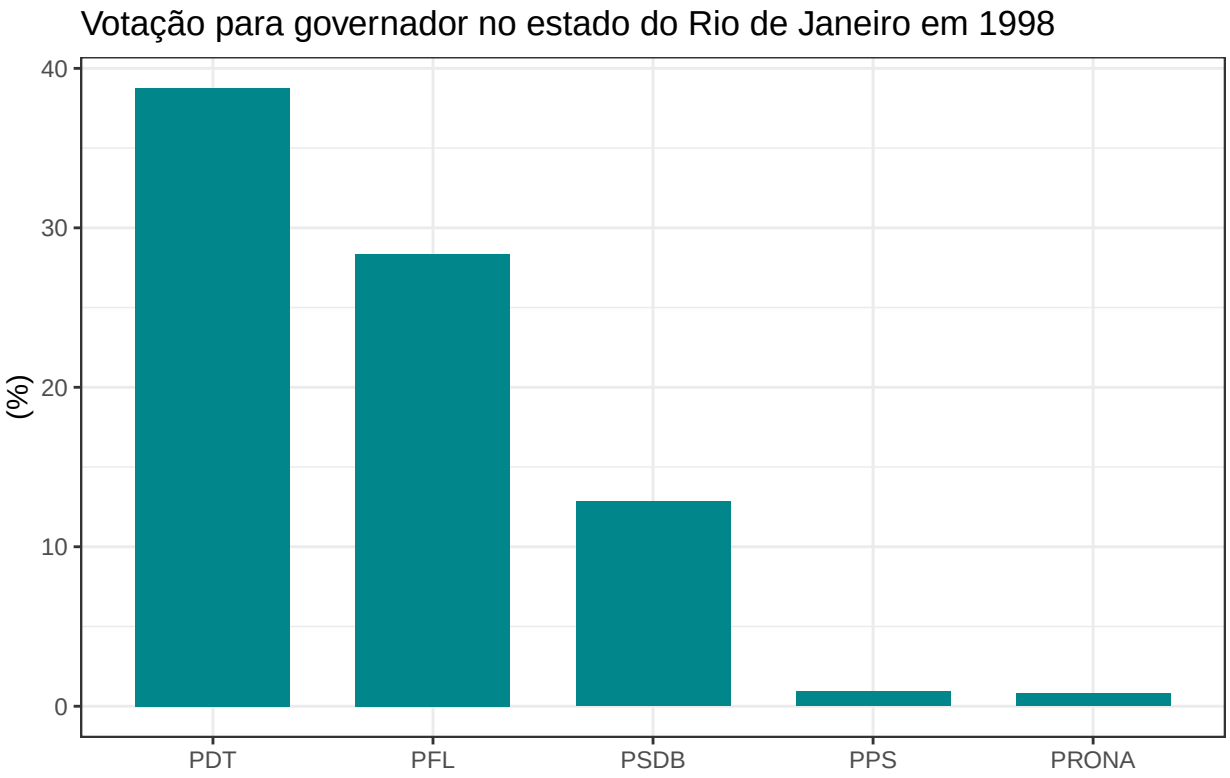

Fonte: TSE

```
##
## $el02
```

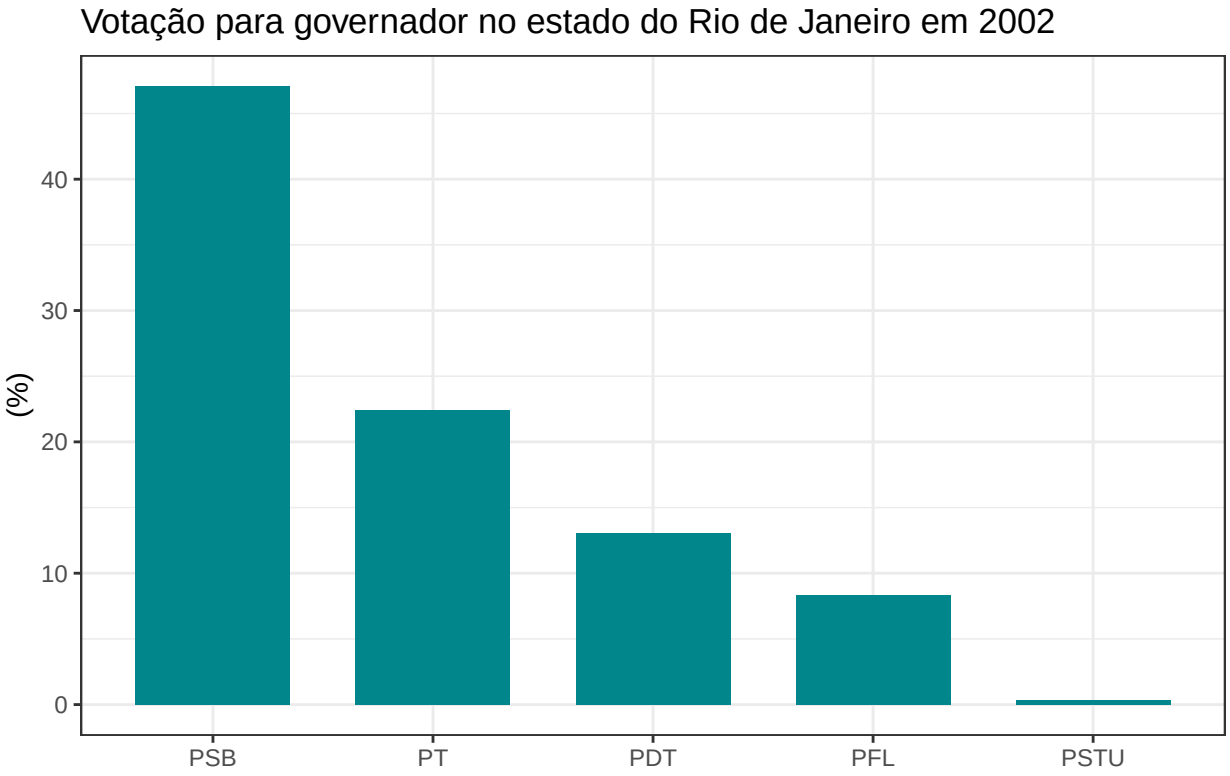

Fonte: TSE

```
##
## $el06
```

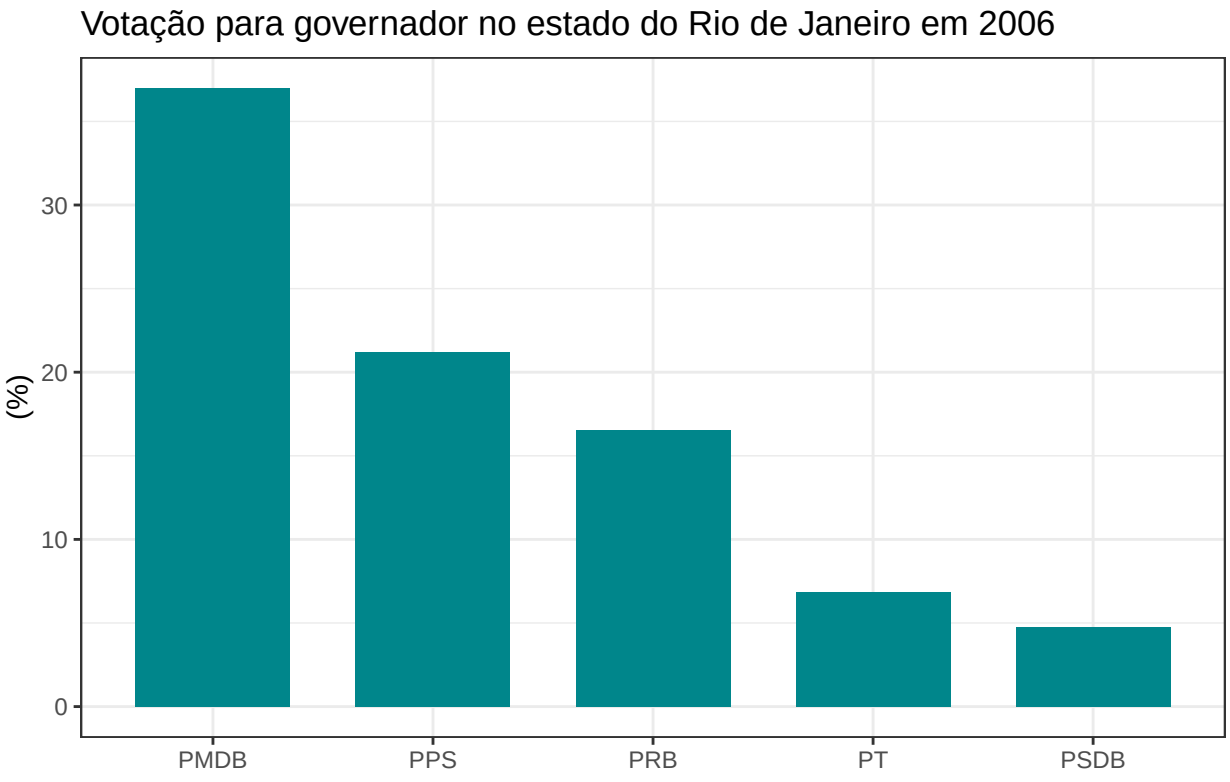

Fonte: TSE

```
##
## $el10
```

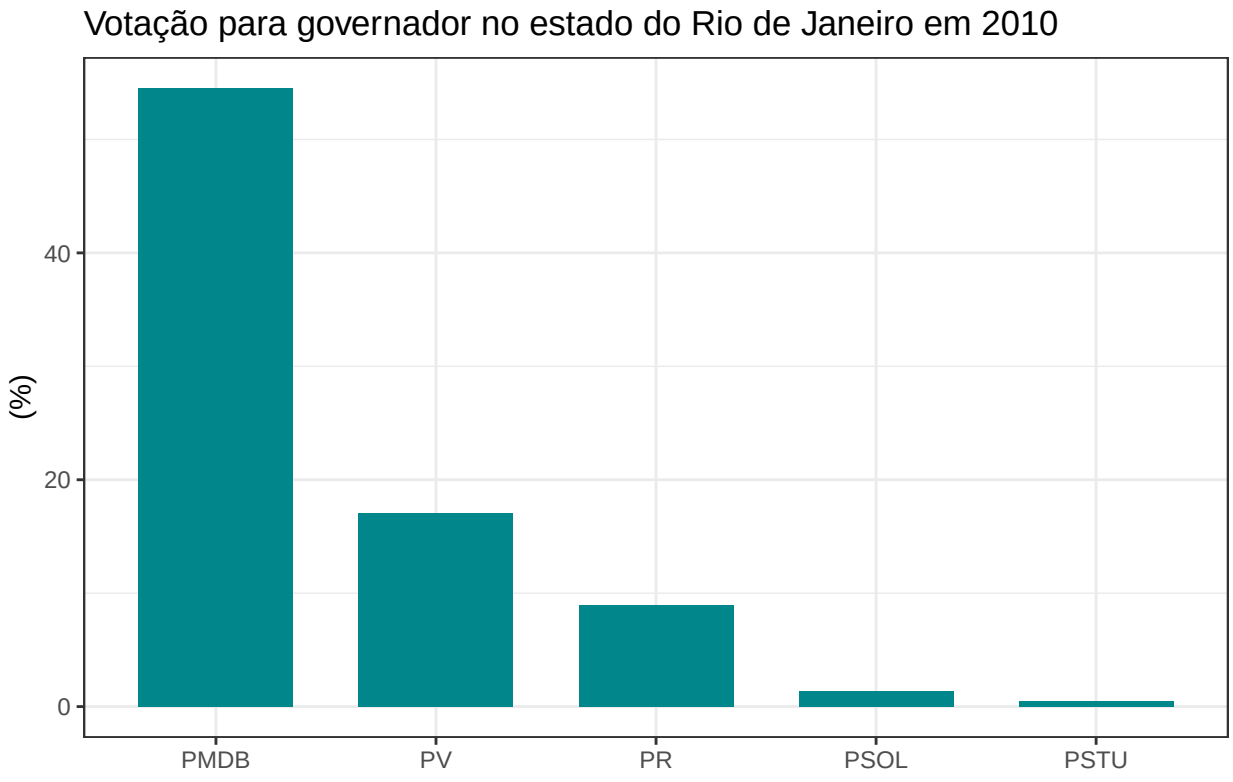

Fonte: TSE

```
map2(.x=maj_rj,
    .y=anos,
    .f= ~gf_barras_cor(.x, .y, "senador", "tomato4"))
```

```
## Selecting by porc_voto
## Selecting by porc_voto
## Selecting by porc_voto
## Selecting by porc_voto
```

```
## $el98
```

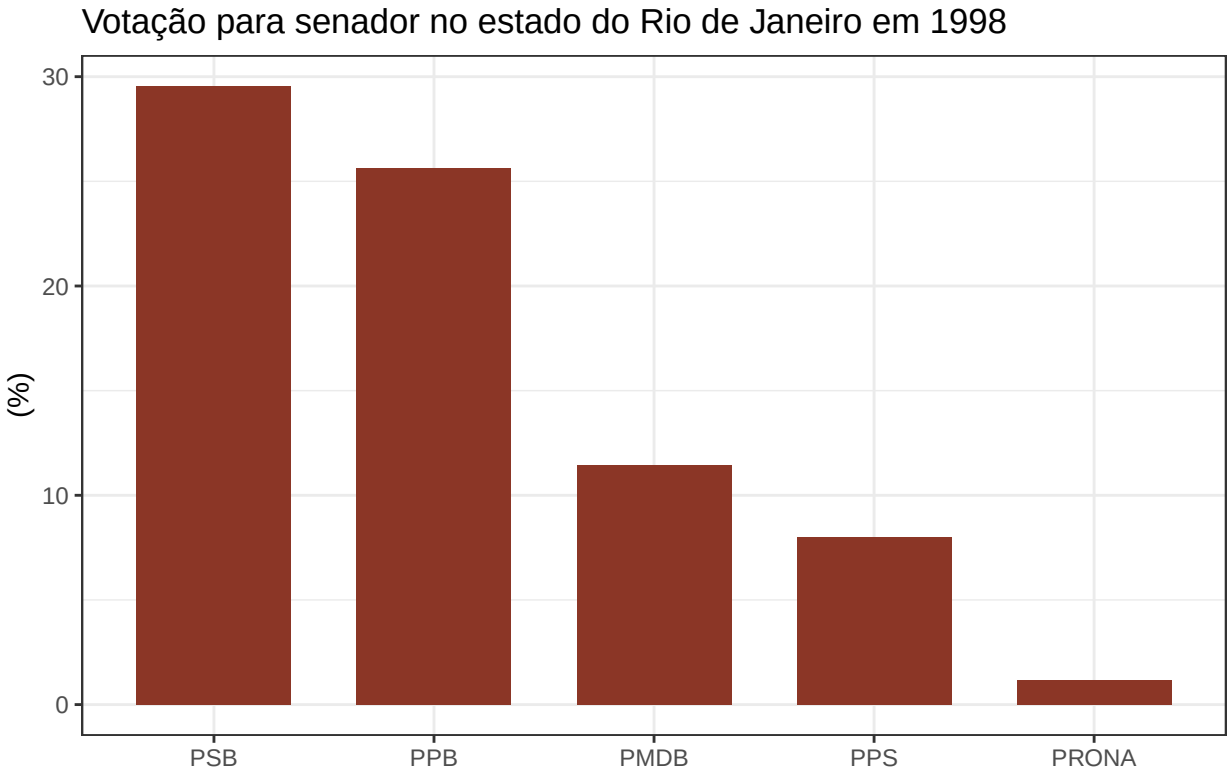

Fonte: TSE

```
##
## $el02
```

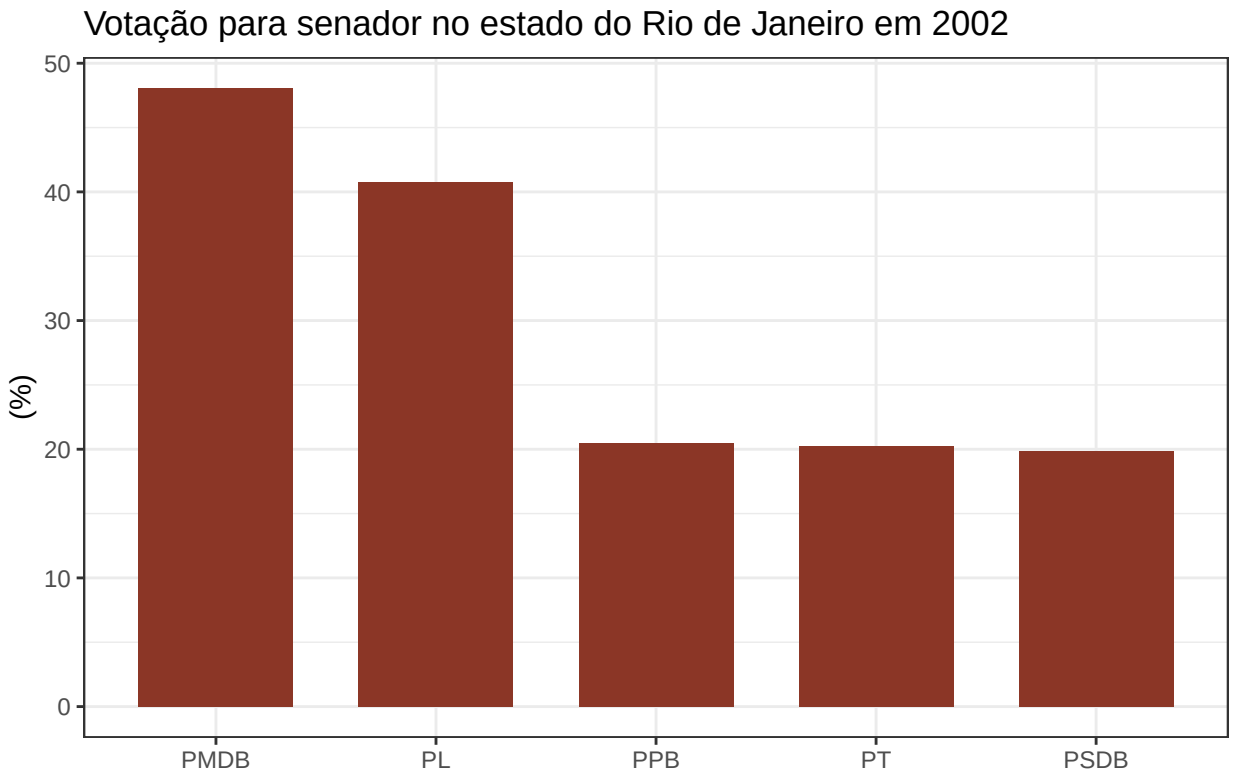

Fonte: TSE

```
##
## $el06
```

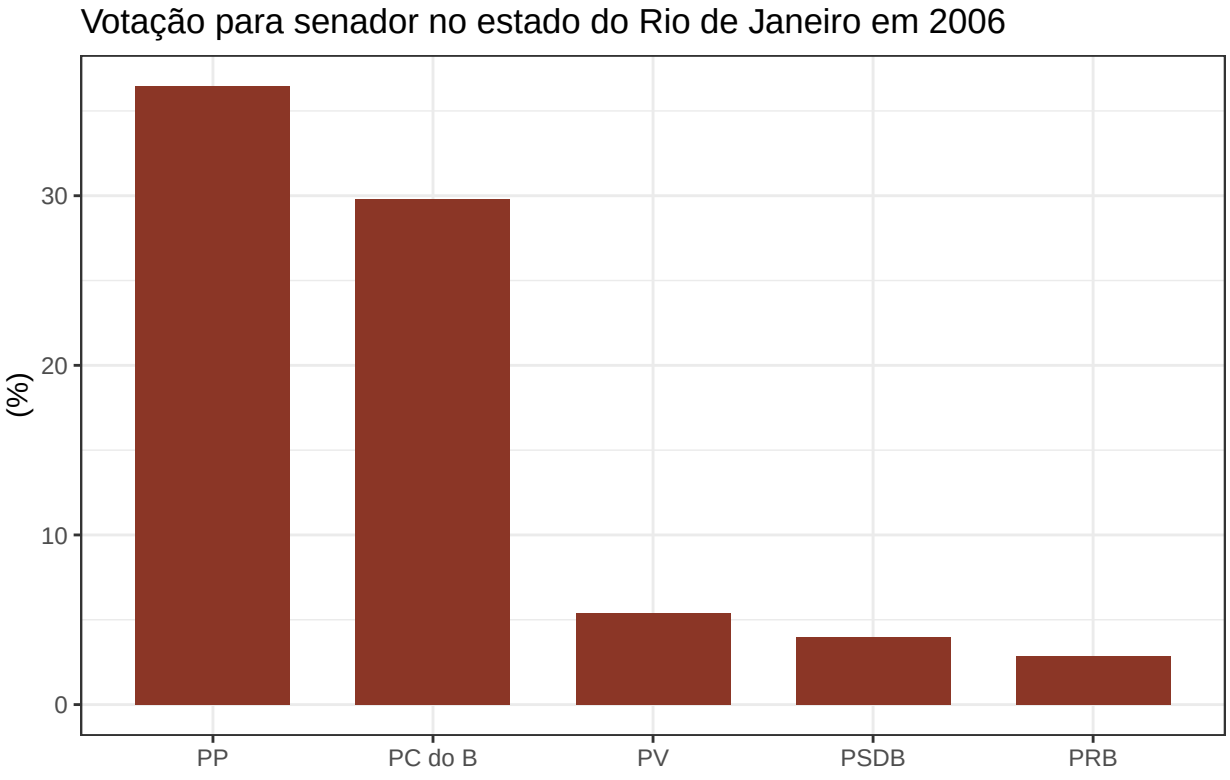

Fonte: TSE

```
##
## $el10
```

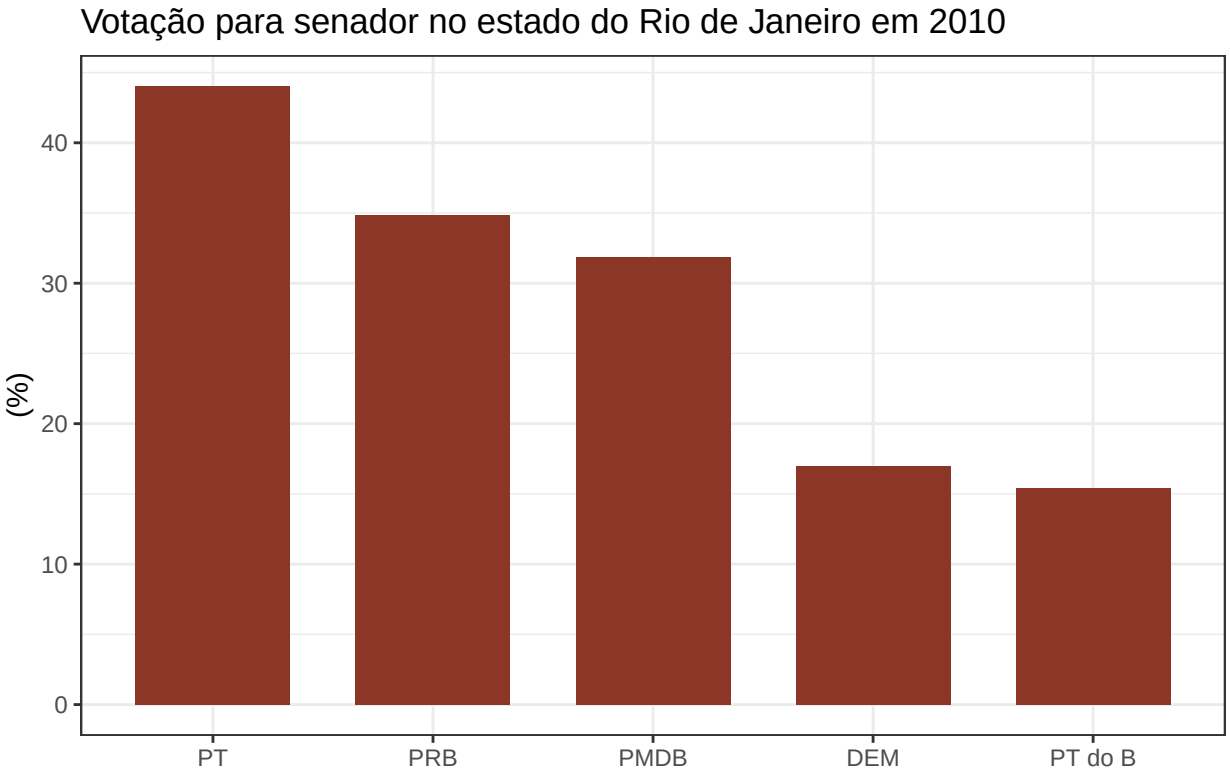

Fonte: TSE

Sei que os códigos ficaram mais complexos ao longo do tutorial, mas vai ficando mais fácil conforme você for praticando. Como em qualquer coisa que se dispuser a aprender na vida, você irá cometer muitos erros no início. Não é fácil, mas é totalmente possível se for persistente. Espero que este material lhe dê os primeiros recursos de que precisa para começar a entender a lógica de programação em R e a automatizar códigos em seus próprios trabalhos. Boa sorte!

Material Adicional:

Para ver com mais detalhes o purrr na prática sugiro esse excelente tutorial da Rebecca Barter. Agora que você já sabe como trablhar com listas será super fácil limpar seus bancos de dados em formato tibble com purrr.

Sugiro também este tutorial sobre como automatizar a criação de seus gráficos com ggplot2 e purrr.

Por fim, este é o meu material de referência quando busco visualizações lindas e super interessantes com ggplot2.